

EchoCem: evaluation de la qualité du ciment par segmentation d'images ultrasoniques par SLB

Félix Fourreau Mathis Wauquiez

École des Ponts ParisTech (ENPC) & ENS Paris-Saclay
{felix.fourreau, mathis.wauquiez}@eleves.enpc.fr

April 4, 2025

Plan

- 1 Introduction
- 2 Données
- 3 Première approche Deep Learning
- 4 Seconde approche Modélisation physique
- 5 Prétraitements Fréquentiels: Fourier et Ondelette
- 6 Filtre de Gabor et Intégration dans la Pipeline
- 7 Post-traitement
- 8 Conclusion

Introduction

- Problématique : segmentation d'images ultrasoniques pour l'évaluation de la qualité du ciment dans les puits pétroliers.
- Objectif : Construire un modèle permettant d'annoter une image de scan pour trouver la position des parois du coffrage en ciment.




Figure: Enter Caption

- Images de scan obtenues par onde de flexion sur 11 puits, avec masques de segmentation indiquant zones d'intérêt pour les 6 premiers puits.
- Patches d'images de dimensions 160×160 et 160×272 .
- Standardisation des patches à la dimension 160×272 par padding gaussien
- Reconstruction de l'image du puit entier
- Redecoupage personnalisé des patch (160×272 ou 272×272)

Première approche Deep Learning

- Utilisation d'un modèle U-Net avec un bloc d'attention.




Figure: Modèle utilisé

- Caractéristiques :
 - Architecture encodeur-décodeur avec connexions résiduelles.
 - Optimisation avec l'algorithme Adam.
 - Fonction de perte hybride combinant Dice Loss et Lovász-Softmax Loss.
- Problème: Mauvaise généralisation (puits 10)

- Modélisation explicite du signal ultrasonique :

$$s(x, t) = A(x)R(t - t_0(x)) + \sum_{i=1}^n B_i(x) R(t - t_0(x) - i \Delta t(x))$$

- Paramètres à estimer :
 - $R(t)$: forme d'un écho.
 - $A(x)$ et $B_i(x)$: amplitudes des échos.
 - $t_0(x)$ et $\Delta t(x)$: délais de propagation.
- Modélise l'écho du casing, de la formation, et la résonance entre le casing et la formation.




Estimer la forme d'un écho $R(t)$

- Approche utilisée: Convolutional Dictionary Learning (CDL)
- Modélisation: $\tilde{s}(x, t) = \sum_{k=1}^K (\mathbf{z}_k(x) * \mathbf{d}_k)(t)$
- Résolution du problème d'optimisation:

$$\min_{(\mathbf{d}_k), (\mathbf{z}_k) \text{ s.c. } \|\mathbf{d}_k\|^2 \leq 1} \frac{1}{2} \sum_{x=1}^N \left\| \mathbf{s}(x) - \sum_{k=1}^K \mathbf{z}_k(x) * \mathbf{d}_k \right\|^2 + \lambda \sum_{x=1}^N \sum_{k=1}^K \|\mathbf{z}_k(x)\|_1$$

- Optimisation alternée

Forme de $R(t)$



- Modèle: $s(x, t) = A(x)R(t - t_0(x)) + \sum_{i=1}^n B_i(x) R(t - t_0(x) - i \Delta t(x))$

$$\min_{A(x), B_i(x), t_0(x), \Delta t(x)} \left\| \tilde{s}_{A, B_i, t_0, \Delta t}(x, t) - s(x, t) \right\|_2^2 + \lambda_1 \text{TV}_x(\Delta t) + \lambda_2 \text{TV}_x(t_0)$$

- Résolution alternée:
 - Trouver $A(x)$ et $B_i(x)$ à $t(x)$ et $\Delta t(x)$ fixés est un problème convexe
 - Trouver $t(x)$ et $\Delta t(x)$ à $A(x)$ et $B_i(x)$ fixés est un problème difficile
 - Solution: Descente de gradient, en utilisant les activations de l'atome comme initialisation
- Modélisation physique + généralisable et interprétable
- Mais comment définir la largeur de la segmentation ?


Prétraitements Fréquentiels: Fourier et Ondelette

● Transformée Fourier :


- Utilisée pour décomposer l'image en fréquences.
- Problème rencontré : difficile de sélectionner une bande de fréquence isolant uniquement les informations nécessaires.

● Transformée en ondelettes :

- Choix de la famille biorthogonale (bior2.2) pour une analyse à 3 niveaux.
- Permet une décomposition multi-échelle avec préservation de la localisation spatiale.



figureTransformée Fourier



figureTransformée en ondelettes

- **Filtre de Gabor :**


- Extraction de caractéristiques locales selon différentes orientations.
- La formule du filtre de Gabor est :

$$G(x, y; \lambda, \theta, \psi, \sigma, \gamma) = \exp\left(-\frac{x'^2 + \gamma^2 y'^2}{2\sigma^2}\right) \cos\left(2\pi \frac{x'}{\lambda} + \psi\right)$$

- Paramètres expérimentaux choisis (fréquences, angles, sigma, etc.).


- **Intégration dans le pipeline :**

- Les canaux extraits (Gabor + coefficients d'ondelettes à 3 niveaux) sont utilisés comme entrées supplémentaires pour le U-Net.
- Objectif : Améliorer la robustesse de la segmentation, notamment sur des puits à faible contraste.



figureFiltre de Gabor

- **Inference** : Pour obtenir le résultat final on construit d'abord l'annotation entière à partir des prédiction de tous les patches de l'image test.
- **Classe 2** :
 - Suppression des points en dehors de l'intervalle position moyenne ± 3 écarts-types.
 - Seuil de probabilité : élimination des points dont la probabilité est inférieure à 10%.
 - Connexion verticale des points proches pour combler les trous.
- **Classe 1 (zones d'intérêt)** :
 - En cas de conflit entre plusieurs composantes, on ne conserve que la region avec la somme de probabilité la plus élevée
 - Seuil de probabilité de 1% pour filtrer les points non significatifs.
 - Priorisation de la classe 2 en cas de superposition.



- La combinaison d'approches deep learning et physiques, enrichie par des analyses fréquentielles, a permis d'améliorer la segmentation.
- Résultat clé : Augmentation significative de l'IoU moyen (0,57 à 0,62).
- Perspectives : explorer l'apprentissage non supervisé et optimiser la modélisation physique.

Merci de votre attention !